



**Universidad De Guayaquil**  
**Facultad De Ciencias Matemáticas y Físicas**  
**Carrera de Ciencias de Datos e Inteligencia Artificial**

**ASIGNATURA**

**INTERCAMBIO DE DATOS EN ENTORNOS DISTRIBUIDOS Y  
VISUALIZACIÓN DE DATOS**

**PROYECTO**

**ALUMNOS:**

**JUSTYN GARCÍA  
ROBERTO ALVAREZ**

**CURSO:**

**CDDEIA-ELNO-5-2**

**CICLO II 2025 – 2026**

## Presentación y contexto

Ecuador atraviesa un episodio del fenómeno de El Niño con proyecciones de intensificación durante el año 2026. Este fenómeno incrementa la temperatura superficial del océano Pacífico, altera los patrones de precipitación en la costa ecuatoriana y eleva el riesgo de inundaciones, deslizamientos y desbordamiento de ríos, particularmente en la cuenca del río Guayas y en ciudades como Guayaquil, Daule y Samborondón.

El objetivo de este proyecto es que los estudiantes diseñen e implementen una plataforma de procesamiento masivo de datos (Big Data) capaz de ingerir, procesar y visualizar en tiempo (cuasi) real información satelital y climática relacionada con El Niño, y que integren dicha información con un componente geoespacial que identifique las zonas de Guayaquil más vulnerables a inundaciones, considerando variables topográficas, hidrológicas y de marea, además de generar rutas de evacuación sugeridas.

El proyecto debe resolverse utilizando un pipeline de datos basado en Apache Kafka (ingesta/streaming), Apache Spark (procesamiento distribuido, preferentemente Structured Streaming) y HDFS (almacenamiento distribuido), integrado con un dashboard interactivo basado en un mapa (OpenStreetMap u otra librería equivalente de código abierto).

## Objetivo general

Diseñar e implementar una arquitectura de procesamiento masivo de datos que permita monitorear en tiempo real la evolución del fenómeno de El Niño y sus efectos hidrometeorológicos en Ecuador, y que traduzca esa información en un mapa de riesgo de inundación para la ciudad de Guayaquil con rutas de evacuación sugeridas.

## Arquitectura del Pipeline de Datos

La solución tecnológica propuesta se fundamenta en una arquitectura de Big Data orientada a eventos (Event-Driven Architecture), diseñada para soportar la ingesta, el procesamiento, el almacenamiento y la visualización de datos climáticos y geoespaciales en tiempo cuasi real. El pipeline de datos consta de cuatro capas principales, integradas de manera secuencial para garantizar escalabilidad, tolerancia a fallos y baja latencia en la entrega de información.

### 1. Capa de Ingesta y Mensajería en Tiempo Real (Streaming)

Para la captura continua de datos provenientes de múltiples fuentes heterogéneas, se ha implementado **Apache Kafka** como sistema distribuido de intermediación de mensajes.

- **Productores de Datos:** Se han desarrollado scripts de extracción que consumen información (vía APIs, descargas programáticas y scraping) desde entidades como NOAA, INAMHI, CELEC EP e INOCAR.
- **Gestión de Tópicos (Topics):** La arquitectura aísla lógicamente los flujos de datos asignando un tópico dedicado a cada fuente específica (por ejemplo, sst-noaa, precip-gpm, nivel-embalse-celec, mareas-inocar).
- **Estandarización:** Los mensajes ingresan al ecosistema serializados en formatos estructurados (JSON o Avro), garantizando que cada registro incluya una marca de tiempo (*timestamp*) fundamental para el análisis temporal.

### 2. Capa de Procesamiento Distribuido y Computación

El motor central de transformación y analítica está soportado por **Apache Spark**, utilizando específicamente el módulo **Structured Streaming** para el procesamiento continuo (o mediante *micro-batches*).

- **Limpieza y Transformación:** Spark actúa como consumidor directo de los tópicos de Kafka, ejecutando tareas de normalización, descarte de valores atípicos y estandarización de esquemas.
- **Operaciones Basadas en Tiempo (Windowing):** Se aplican ventanas de tiempo para calcular métricas derivadas críticas, tales como los acumulados de precipitación en la última hora o en las últimas 24 horas.
- **Cálculo del Índice de Riesgo:** En esta capa se ejecuta la lógica central del negocio: la agregación de variables hidrometeorológicas (lluvia, nivel de marea, estado del embalse) para generar un índice compuesto de riesgo de inundación sectorizado para la ciudad de Guayaquil.

### 3. Capa de Almacenamiento Distribuido (Data Lake)

El resguardo de la información, tanto histórica como procesada, se gestiona a través del **Hadoop Distributed File System (HDFS)**, estructurado bajo el paradigma de zonas de un Data Lake para facilitar su gobernanza.

- **Zona Raw (Cruda):** Almacena una copia inmutable de los datos originales exactamente como fueron ingeridos desde Kafka, sirviendo como respaldo histórico y permitiendo la reprocesamiento en caso de fallos.
- **Zona Processed (Refinada):** Contiene los DataFrames limpios y transformados por Spark, listos para su consumo analítico.
- **Optimización y Particionamiento:** Los datos en la zona procesada se almacenan utilizando **Apache Parquet**, un formato columnar altamente eficiente para consultas analíticas. Adicionalmente, la información se encuentra particionada jerárquicamente por *fecha* y por *fuentes*, lo que optimiza significativamente los tiempos de lectura.

#### 4. Capa de Servicio y Visualización Espacial

El último eslabón del pipeline es el encargado de exponer el valor analítico a los usuarios finales a través de una interfaz gráfica e interactiva.

- **API de Exposición:** Se ha desarrollado un servicio web ligero (basado en frameworks como Flask, FastAPI o Node.js) que actúa como puente, extrayendo los datos consolidados y sirviéndolos a la capa de presentación.
- **Dashboard Geoespacial:** La interfaz de usuario consta de un mapa interactivo construido sobre tecnologías de código abierto (Leaflet o Mapbox GL sobre teselas de OpenStreetMap).
- **Interactividad y Ruteo:** El sistema permite la activación dinámica de capas de vulnerabilidad (topografía, marea, precipitación) para visualizar escenarios combinados de riesgo. Además, integra un motor de ruteo espacial (como OSRM o pgRouting) capaz de calcular en tiempo real las rutas de evacuación óptimas desde los sectores anegados hacia zonas seguras predefinidas.



# ARQUITECTURA DEL PIPELINE RIESGO DE INUNDACIÓN EN ECUADOR

Ingesta de datos → Procesamiento en tiempo real → Almacenamiento → API → Dashboard

## 1 FUENTES DE DATOS Y PRODUCTORES

### 1.1 MeteorologíaProducer (Java)



- ✓ Consulta API Open-Meteo
- ✓ Obtiene precipitación actual por provincia
- ✓ Convierte a JSON
- ✓ Envía a Kafka

Datos:  
Precipitación

### 1.2 MareaProducer (Java)



- ✓ Genera datos simulados de marea para provincias costeras
- ✓ Altura de marea
- ✓ Estado de la marea
- ✓ Envía a Kafka

Datos:  
Mareas

Provincias  
Guayas  
Manabí  
Santa Elena  
Esmeraldas  
El Oro  
(y todas las provincias del Ecuador para meteorología)

## 2 APACHE KAFKA (MENSAJERÍA)



Cluster Kafka



Tópico:  
precip-gpm  
(Precipitación)



Tópico:  
mareas-inocar  
(Mareas)



Kafka actúa como buffer de eventos en tiempo real, desacoplando productores y consumidores.

## 3 PROCESAMIENTO STREAMING

(ClimaStreamingProcessor - Java / Spark)



Structured Streaming

### 1. Lectura de tópicos Kafka



Lee datos de:  
• precip-gpm  
• mareas-inocar

### 2. Conversión a DataFrames



Parseo de JSON y estructura de datos

### 3. Sincronización



Unión de flujos por ventana de tiempo (time window)

### 4. Cálculo de Riesgo



Combina precipitación + marea para determinar el nivel de riesgo

### 5. Escritura en HDFS



Guarda resultados en formato Parquet

### Reglas de Riesgo (ejemplo)

- Precipitación Alta + Marea Alta = **Riesgo Muy Alto**
- Precipitación Media + Marea Alta = **Riesgo Alto**
- Precipitación Alta + Marea Media = **Riesgo Alto**
- Precipitación Baja + Marea Baja = **Riesgo Bajo**

## 4 ALMACENAMIENTO (HDFS)



HDFS

### Ruta en HDFS:

/user/root/processed/riesgo\_combinado

Formato: Parquet



Almacena los resultados procesados de forma particionada y optimizada para consultas rápidas.

## 5 API (FASTAPI - PYTHON)



### 1. Lector HDFS



Cada 10 segundos lee nuevos datos desde HDFS

### 2. Procesamiento



Carga datos, ordena por fecha y obtiene el último registro por provincia

### 3. API REST



Expone endpoint /api/clima (devuelve JSON)

### Respuesta JSON

Datos del último registro de cada provincia con:

- Precipitación
- Altura de marea
- Nivel de riesgo
- Timestamp

## 6 DASHBOARD WEB (HTML/CSS/JS)



Consume API  
GET /api/clima

### Muestra en tiempo real:

- Mapa de Ecuador
- Nivel de riesgo por provincia (colores)
- Precipitación actual
- Altura de marea
- Última actualización



● Muy Alto ● Alto ● Medio ● Bajo

### FLUJO DE DATOS

- Datos originales (APIs/Simulados)
- Eventos Kafka
- Datos procesados
- Consultas / Respuestas

### TECNOLOGÍAS UTILIZADAS



Java 17



Kafka



Apache Spark



HDFS



Python



HTML, CSS, JS

### CARACTERÍSTICAS CLAVE

- ✓ Procesamiento en tiempo real
- ✓ Arquitectura escalable y desacoplada
- ✓ Almacenamiento eficiente (Parquet en HDFS)
- ✓ Visualización en tiempo real
- ✓ Tecnologías Big Data de uso real en la industria

## Fase 1: Ingesta de Datos en Tiempo Real (Streaming)

La primera etapa del proyecto consiste en implementar un pipeline de ingesta de datos en tiempo real usando Apache Kafka. Este componente actúa como la puerta de entrada del sistema y debe ser capaz de recibir información proveniente de distintas fuentes climáticas y satelitales (o de servicios que las repliquen).

### 1.1 Identificación y Consumo de Fuentes de Datos

Para alimentar el sistema con información veraz sobre la evolución del fenómeno de El Niño y sus efectos hidrometeorológicos, se debe identificar, documentar y consumir al menos una fuente de información por cada categoría requerida. La ingesta de estos datos se realiza a través de integraciones vía API, descargas programáticas o *scraping* autorizado.

Las categorías y fuentes implementadas son:

- **Monitoreo de El Niño (nivel nacional/regional):** Incluye fuentes como los boletines y probabilidades de ENSO del NOAA Climate Prediction Center (CPC), los pronósticos probabilísticos del IRI Columbia, estimaciones de precipitación de la NASA GPM o Copernicus, y estaciones meteorológicas del INAMHI.
- **Afectaciones e infraestructura hídrica en Ecuador:** Comprende los niveles del embalse Daule-Peripa vía CELEC EP, las alertas y reportes de la SNGR, y las tablas de mareas del estuario del Golfo de Guayaquil proveídas por el INOCAR.

### 1.2 Diseño de la Topología en Apache Kafka

El proyecto debe resolverse utilizando un pipeline de datos basado en Apache Kafka para la etapa de ingesta y streaming. Para mantener el aislamiento lógico, la trazabilidad y el orden de los eventos, la arquitectura tecnológica requiere crear un topic específico por cada fuente de datos.

### 1.3 Justificación y Selección de la Fuente de Datos Meteorológicos Reales

Para cumplir con los objetivos del proyecto y los requerimientos de la rúbrica de evaluación respecto a la Calidad e integración de fuentes de datos, el diseño del pipeline requería sustituir las cargas útiles simuladas (*mock data*) por mediciones de precipitación reales. Las instrucciones del proyecto sugieren la exploración de organismos oficiales como el **INAMHI** ([inamhi.gob.ec](http://inamhi.gob.ec)) y la **NASA GPM** ([gpm.nasa.gov](http://gpm.nasa.gov)).

Sin embargo, tras un análisis técnico de la infraestructura de estas entidades, se identificaron las siguientes limitaciones operativas para un entorno de *streaming processing* en tiempo cuasi real:

1. Las estaciones meteorológicas automatizadas locales del **INAMHI** publican sus consolidados mediante boletines periódicos fijos o portales visuales interactivos cerrados, careciendo de un endpoint analítico público y gratuito tipo API REST que devuelva estructuras de datos estandarizadas (JSON) bajo demanda automatizada.

2. Los repositorios de datos satelitales de la misión **NASA GPM** operan bajo un paradigma orientado a lotes (*batch processing*), distribuyendo archivos geoespaciales inmensos y de alta densidad (formatos HDF5 o NetCDF). Procesar estos binarios directamente en la primera milla del pipeline de ingesta local penalizaría críticamente la latencia de la arquitectura y la memoria de red.

### 1.3.1 Solución Arquitectónica: API REST de Open-Meteo

Frente a estos desafíos, se seleccionó como la fuente analítica principal la plataforma **Open-Meteo**. Esta API web funciona como un agregador y optimizador de datos meteorológicos a escala global que integra de forma automatizada los modelos de predicción numérica y mediciones satelitales internacionales más avanzados, incluyendo el modelo de predicción global **GFS de la NOAA**, y las recalibraciones de misiones meteorológicas espaciales homólogas a la NASA.

La adopción de Open-Meteo como origen de datos proporciona ventajas clave para la robustez del sistema:

- **Conformidad con el Paradigma de Streaming:** Expone interfaces basadas en el protocolo **HTTP/REST** bajo arquitectura *Stateless*, facilitando que el productor nativo desarrollado en Java realice peticiones asíncronas de manera ágil.
- **Formatos Estructurados Universales:** Entrega las respuestas directamente codificadas en formato **JSON**. Esto anula la necesidad de incorporar pesadas librerías de descompresión geoespacial en la fase de ingesta, permitiendo que el objeto sea interpretado inmediatamente mediante la librería Gson para ser transformado y enviado al bus de mensajería de Kafka.
- **Resolución Geoespacial Nacional Dinámica:** Permite la parametrización dinámica mediante coordenadas geográficas (Latitud y Longitud). Esto hizo posible construir una matriz de mapeo nacional indexando los centros geográficos de las **24 provincias del Ecuador**, logrando una cobertura federal del estado pluviométrico en tiempo cuasi real.
- **Gobernanza y Viabilidad Operativa:** Al ser una API de acceso abierto sin requerimientos estrictos de autenticación forzada (*API Keys* corporativas o tokens de pago), mitiga los riesgos de denegación de servicio por cuotas excesivas durante el desarrollo, siempre y cuando se respete un retardo prudencial (en este caso, 1.5 segundos entre consultas por provincia) para evitar políticas de bloqueo por tráfico masivo.

**Levantar el motor de Kafka (código fuente)**

```
./gradlew jar -x test
```

**Terminal 1: El Cerebro (ZooKeeper)**

```
./bin/zookeeper-server-start.sh ./config/zookeeper.properties
```

**Terminal 2: El Servidor (Kafka Broker)**

```
./bin/kafka-server-start.sh ./config/server.properties
```

**Terminal 3: La Entrada de Datos (Productor)**

```
./bin/kafka-topics.sh --create --topic precip-gpm --bootstrap-server localhost:9092
```

**Terminal 4: La Salida de Datos (Consumidor)**

```
./bin/kafka-console-consumer.sh --topic test-stream-out --from-beginning --bootstrap-server localhost:9092
```

```
./bin/kafka-console-consumer.sh --topic precip-gpm --from-beginning --bootstrap-server localhost:9092
```

**1.4 Validación Experimental de la Capa de Ingesta**

Para garantizar la correcta operatividad de la arquitectura orientada a eventos, se procedió a realizar una prueba de integración del flujo de datos en tiempo real entre el entorno de desarrollo y el clúster local de mensajería.

**1.4.1 Resultados de la Ingesta de Datos (Logs del Productor)**

Al ejecutar de forma nativa la clase empaquetada `org.example.MeteorologiaProducer`, el hilo del proceso inicializó el cliente de Kafka apuntando al broker local (`localhost:9092`). El productor simuló de manera exitosa el comportamiento de los sensores del INAMHI en la provincia del Guayas, estructurando y transmitiendo cargas útiles en formato JSON de forma continua hacia el tópico `precip-gpm`.



```

12 public class MeteorologiaProducer {
13     public static void main(String[] args) {
14         while (true) {
15             // 3. Simular estructura JSON requerida para el fenómeno de El Niño
16             JSONObject jsonRecord = new JSONObject();
17             jsonRecord.addProperty("fuente", "INAMHI_Estacion_Guayas");
18             jsonRecord.addProperty("provincia", "Guayas");
19             jsonRecord.addProperty("canton", "Guayaquil");
20             // Genera lluvias simuladas entre 0.0 y 50.0 mm
21             jsonRecord.addProperty("precipitacion_mm", Math.round(random.nextDouble() * 50));
22             // Inclusión obligatoria de la marca de tiempo
23             jsonRecord.addProperty("timestamp", System.currentTimeMillis());
24         }
25     }
26 }

```

Run MeteorologiaProducer

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":38.1,"timestamp":1783543995791}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":17.5,"timestamp":1783544000793}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":33.8,"timestamp":1783544005794}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":32.5,"timestamp":1783544010795}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":28.3,"timestamp":1783544015796}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":44.9,"timestamp":1783544020796}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":1.5,"timestamp":1783544025798}

Mensaje enviado con éxito: {"fuente":"INAMHI\_Estacion\_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion\_mm":9.9,"timestamp":1783544030798}

```

precipitacion_mm":13.2,"timestamp":1783543995791}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":22.0,"timestamp":1783544000793}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":33.8,"timestamp":1783544005794}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":32.5,"timestamp":1783544010795}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":28.3,"timestamp":1783544015796}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":44.9,"timestamp":1783544020796}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":1.5,"timestamp":1783544025798}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":9.9,"timestamp":1783544030798}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":46.7,"timestamp":1783544035801}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":4.2,"timestamp":1783544040802}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":29.0,"timestamp":1783544045803}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":42.4,"timestamp":1783544045804}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":40.3,"timestamp":1783544050804}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":46.2,"timestamp":1783544055842}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":45.3,"timestamp":1783544060843}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":28.6,"timestamp":1783544065844}
{"fuente":"INAMHI_Estacion_Guayas","provincia":"Guayas","canton":"Guayaquil","precipitacion_mm":10.5,"timestamp":1783544070845}

```

## 1.4.2 Confirmación del Lado del Consumidor

La validación del pipeline *End-to-End* se completó al verificar la Terminal 4 del clúster (instanciada mediante el script ejecutable `./bin/kafka-console-consumer.sh`). El consumidor acoplado al tópico `precip-gpm` reflejó la recepción inmediata, asíncrona y sin pérdidas de cada uno de los paquetes de datos emitidos por la aplicación de Java. Con esto, queda demostrado que la infraestructura base está lista para soportar la persistencia de datos y el análisis de ventanas temporales.

## Fase 2: Procesamiento Distribuido en Tiempo Cuasi Real

La segunda etapa de la arquitectura tecnológica comprende el consumo y la transformación analítica de las corrientes de datos procedentes de Apache Kafka utilizando **Apache Spark**. Para dar cumplimiento a los requerimientos técnicos de la plataforma, se optó por el módulo **Spark Structured Streaming**, el cual extiende el motor de Spark SQL para tratar los flujos continuos bajo un modelo de tablas infinitas optimizadas en memoria.

### 2.1 Estrategia de Micro-Lotes (Micro-batches) y Ventanas Temporales

Por la naturaleza hidrometeorológica del fenómeno de El Niño, el análisis de inundaciones no puede depender de eventos aislados, sino del comportamiento pluviométrico acumulado. El motor de streaming procesa la información dividiendo el flujo infinito en paquetes discretos o micro-lotes espaciados de manera regular (por ejemplo, cada 10 segundos).

Las operaciones analíticas centrales en esta capa incluyen:

- **Deserialización y Tipado Dinámico:** Los valores binarios encapsulados en el objeto de mensajería de Kafka se parsean y proyectan sobre un esquema fuertemente tipado (Schema) compuesto por campos de tipo texto (StringType), numérico preciso (DoubleType) y marcas de tiempo (TimestampType).
- **Cálculo de Agregaciones con Windowing:** El sistema aplica ventanas de tiempo deslizantes (Sliding Windows) sobre el campo timestamp del evento. Esto permite calcular en tiempo real métricas analíticas esenciales como el volumen de precipitación acumulado en milímetros (precipitacion\_mm) por cada cantón o provincia, identificando picos de saturación hídrica en la cuenca del Guayas.

### 2.2 Validación Experimental de la Capa de Procesamiento Distributed (Spark Logs)

Una vez corregida la compatibilidad del entorno de ejecución mediante el uso del JDK 17 (revocando el fallo de métodos de seguridad obsoletos de JAAS detectados en compilaciones superiores), el motor de **Spark Structured Streaming** se acopló exitosamente al broker de Kafka local en el puerto 9092.

El sistema procesa los flujos bajo el esquema de ventanas asíncronas discretas. A continuación, se documenta el volcado estructural de la consola analítica (Console Sink) durante el procesamiento estable de los micro-lotes. Se constata la correcta deserialización del formato JSON, la proyección del esquema tipado y la inyección exitosa de la capa lógica condicional que determina los niveles de saturación pluvial por provincia.

#### 2.2.1 Mitigación de Dependencias de Sistema de Archivos en Entornos Windows

Durante el despliegue del Job de procesamiento distribuido en el sistema operativo anfitrión (Windows), se identificó una excepción de tipo FileNotFoundException debido a la ausencia de las variables globales HADOOP\_HOME. Dado que Apache Spark requiere de abstracciones del sistema de archivos POSIX para la gestión de metadatos de los micro-lotes, la ejecución nativa en Windows suele requerir el binario de emulación winutils.exe.

### 2.2.2 Enlace de Bibliotecas Dinámicas de Seguridad (JNI Linkageer Error)

Durante la inicialización del hilo de ejecución asíncrono en Spark Structured Streaming, se detectó una excepción de tipo `UnsatisfiedLinkError` asociada al método nativo `NativeIO$Windows.access0`. Este comportamiento responde a la necesidad del subsistema de archivos de Hadoop de validar privilegios de seguridad POSIX sobre la plataforma Windows mediante llamadas JNI.

### 2.3 Resultados Analíticos de la Capa de Procesamiento (Para tu Informe)

Como evidencia del correcto funcionamiento del motor de **Spark Structured Streaming**, se adjunta el volcado de consola de los micro-lotes procesados de forma estable en el entorno de desarrollo. Cada lote discretiza y procesa los eventos JSON distribuidos por Kafka, traduciendo de manera exitosa los *timestamps* UNIX a fechas locales y aplicando las reglas lógicas de negocio en tiempo cuasi real.

**2.4 Resolución de Políticas de Acceso (ACLs) hacia HDFS Contenerizado** Durante la etapa de persistencia de datos (escritura de los micro-lotes en el sistema de archivos distribuido), la comunicación entre el Driver de Spark en el host de Windows y el clúster virtualizado de Hadoop fue denegada por una discrepancia en las listas de control de acceso (ACL). El motor de Spark heredó las credenciales del sistema operativo anfitrión, intentando realizar operaciones de escritura bajo un perfil no reconocido por el NameNode de HDFS, el cual reserva sus cuotas de escritura al superusuario root.

localhost:9870/explorer.html#/user/root/processed/clima

| Permission | Owner | Group      | Size | Last Modified | Replication | Block Size | Name                 |
|------------|-------|------------|------|---------------|-------------|------------|----------------------|
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | _spark_metadata      |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:36  | 0           | 0 B        | provincia=Azuay      |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:36  | 0           | 0 B        | provincia=Bolivar    |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:36  | 0           | 0 B        | provincia=Canar      |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:36  | 0           | 0 B        | provincia=Carchi     |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Chimborazo |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Cotopaxi   |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=El%20Oro   |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Esmeraldas |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Galapagos  |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Guayas     |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Imbabura   |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Loja       |
| drwxr-xr-x | root  | supergroup | 0 B  | Jul 10 16:37  | 0           | 0 B        | provincia=Los%20Rios |

```

System.out.println("Spark inicializado correctamente con librerias dinamicas nativas.");

Batch: 2
+-----+
|fuente|provincia|latitud|longitud|precipitacion_mm|timestamp|fecha_evento|nivel_alerta|
+-----+
|Modelo_Global_Satelital|Azuay|-2.9801|-79.0059|0.5|1783635936536|2026-07-09 17:25:36|Lluvia Ligera|
+-----+

Batch: 3
+-----+
|fuente|provincia|latitud|longitud|precipitacion_mm|timestamp|fecha_evento|nivel_alerta|
+-----+
|Modelo_Global_Satelital|Bolivar|-1.5916|-79.0022|0.6|1783635938281|2026-07-09 17:25:38|Lluvia Ligera|
+-----+

```

### Fase 3: Almacenamiento Distribuido (Data Lake en HDFS)

La tercera etapa de la arquitectura garantiza la persistencia, disponibilidad y gobernanza de la información analítica generada por el motor de *streaming*. Para esto, se configuró una canalización de escritura desde el nodo maestro de Spark hacia el clúster virtualizado de Hadoop (HDFS).

**3.1 Estructura del Data Lake y Formato Columnar** Los micro-lotes procesados y enriquecidos con el índice de riesgo combinado son depositados en la zona *Processed* del Data Lake (específicamente bajo la ruta `hdfs://namenode:9000/user/root/processed/riesgo_combinado`). Para optimizar el rendimiento de las consultas posteriores, el sistema serializa los DataFrames utilizando Apache Parquet. Este formato columnar ofrece altas tasas de compresión y eficiencia en operaciones de lectura, características indispensables en ecosistemas de Big Data.

**3.2 Estrategia de Particionamiento Dinámico** Para evitar cuellos de botella durante la fase de lectura de la API, se implementó una estrategia de particionamiento jerárquico por la variable de segmentación geográfica. El motor de Spark divide dinámicamente los datos y genera subdirectorios independientes (provincia=Guayas, provincia=Manabi, etc.). Esto permite que las consultas futuras filtren los metadatos a nivel de disco, reduciendo drásticamente la carga de red y memoria.

### Fase 4: Servicio REST y Dashboard Geoespacial

El último eslabón de la arquitectura adopta un enfoque desacoplado, separando la lógica de extracción de datos de la de renderizado en el cliente mediante una arquitectura cliente-servidor tradicional.

**4.1 Desarrollo de la API de Exposición (FastAPI)** Para exponer los datos almacenados en HDFS de forma segura y ágil, se desarrolló un microservicio backend utilizando **FastAPI** (Python).

- **Lectura Nativa:** La API integra librerías como *pandas* y *pyarrow* para leer directamente los bloques Parquet desde la carpeta `riesgo_combinado` alojada en Hadoop.
- **Transformación y Servicio:** El servicio extrae los registros más recientes (basados en el *timestamp* de agregación de Spark) y serializa la respuesta en formato JSON a través del *endpoint* REST `/api/clima`.

**4.2 Dashboard Interactivo (Leaflet y OpenStreetMap)** El cliente web se diseñó con un enfoque de experiencia de usuario (UX) inmersivo, utilizando principios de diseño *Glassmorphism*.

- **Mapeo Cartográfico Dual:** La plataforma utiliza la librería **Leaflet** renderizada por defecto sobre teselas oscuras (Dark Mode) de CARTO. Adicionalmente, incorpora




un **Toggle Satelital** que permite al usuario conmutar dinámicamente hacia las imágenes fotorrealistas de ESRI (*World Imagery*), lo que facilita el reconocimiento de la topografía urbana real al evaluar zonas inundadas.

- **Lógica de Capas por Intersección Inteligente:** A través de controles unificados que dividen la pantalla simétricamente, el usuario interactúa con dos factores: Lluvia y Marea. La interfaz evalúa el estado de estos botones:
  1. Si solo uno está activo, muestra exclusivamente sus respectivos niveles (acumulación en mm o altura en m).
  2. Si **ambos** están activos simultáneamente, el sistema aplica una "intersección visual", ocultando las capas individuales y proyectando únicamente la **Capa de Riesgo Combinado** (identificando zonas de represamiento en alerta roja).
- **Live Feed (Reportes en Vivo):** Se implementó un panel de *streaming* lateral que intercepta los datos entrantes cada 10 segundos y genera una bitácora automatizada estilo *chat*. Muestra la marca de tiempo, la precipitación, una métrica simulada de vientos cruzados y el estado de riesgo de las provincias afectadas, eliminando mensajes antiguos para evitar fugas de memoria.

**4.3 Integración de Ruteo de Evacuación Avanzado (OSRM) y Simulador** Para dar respuesta operativa a los escenarios de crisis, se integró el motor de ruteo espacial **OSRM**.

- **Generación Aleatoria y Algoritmo de Distancia Euclidiana:** Cuando una provincia alcanza "Riesgo Crítico", el sistema habilita el trazado de rutas. Al accionarlo, el algoritmo inyecta aleatoriamente múltiples puntos vulnerables (simulando barrios inundados en un radio de ~15km). Inmediatamente después, calcula la distancia euclidiana hacia una matriz de "Zonas Seguras/Albergues" procedimentalmente generada para dicha provincia (ej. hospitales, coliseos, cotas altas) y enlaza cada sector vulnerable con su refugio más cercano mediante peticiones OSRM. Las rutas no se borran al iterar sobre el mapa, permitiendo trazar evacuaciones a escala nacional.
- **Simulador Inyectable:** Se incluye un botón de "Simular Tormenta" que sobrescribe temporalmente los datos para forzar una anomalía pluviométrica masiva (>125 mm) combinada con pleamar. Esto detona instantáneamente toda la lógica visual de alertas rojas en la interfaz.



## 5. Conclusiones

1. **Robustez y Baja Latencia:** La implementación de una arquitectura *Event-Driven* basada en **Apache Kafka** y **Spark Structured Streaming** demostró ser altamente resiliente. La plataforma logró ingerir, transformar y analizar flujos asíncronos en tiempo cuasi-real, logrando integrar APIs reales (Open-Meteo) y flujos modelados (INOCAR) eficientemente.
2. **Eficiencia en el Almacenamiento:** El uso de **HDFS** como Data Lake, acoplado a la compresión columnar de Apache Parquet (/riesgo\_combinado) y al particionamiento geográfico dinámico, resolvió los desafíos de volumen y velocidad, garantizando que el microservicio en Python (FastAPI) acceda siempre al estado actualizado del clima en milisegundos.
3. **Valor Operativo:** El proyecto trasciende la simple visualización de datos climáticos al incorporar analítica geoespacial inteligente. La capacidad de detectar el represamiento de las redes de alcantarillado, unida al algoritmo de **rutas simultáneas** de OSRM orientadas al refugio más cercano y a los reportes dinámicos (Live Feed), cierra el ciclo del sistema de alerta temprana. Convierte datos crudos en inteligencia accionable y a prueba de fallos, ideal para la mitigación del Fenómeno de El Niño.